standalone에 붙인 pyspark spark job 실행해보기

About

pyspark application을 standalone에 띄우고 여기서 spark job을 실행해본다. 그 결과를 standalone UI를 통해서 확인한다.

Prerequisite

standalone, spark가 깔려 있어야 한다.

Let's get started!

먼저, application으로 pyspark shell을 띄운다. 참고로 spark shell은 scala 기반, pyspark shell은 파이썬 기반 이다.

위고 싶은 파일을 정하자. 나는 /kikang/spark3/README.md 로 정했다. pyspark shell에 들어가있는 상태에서 경로에 맞게 README.md 파일을 불러와보자. (현재 나는 /kikang/spark3에 있다.)

```
$ rdd = sc.textFile('README.md')
```

스파크는 기본적으로 lazy evaluation을 한다. 즉, 위 명령어를 실행한다고 해서 바로 README.md을 읽어오지 않는다. 아래의 action을 발생시키는 코드를 실행해야지 스파크는 그제서야 코드를 실행하기 시작한다.

```
$ rdd.count()
```

만약 위 코드를 실행했는데, 파일을 hdfs://에서 찾을 수 없다는 에러가 뜬다면 두 가지 해결책이 있다.

첫 번째는 hdfs에 README.md을 올리는 것이다. hdfs라는, 마스터와 워커 모두가 공유할 수 있는 저장 시스템에 README.md을 올림으로써 한번에 접근 가능하도록 한다.

두 번째는 파일을 읽는 경로를 달리하는 것이다. 즉, hdfs://가 아니라 file://부터 시작하여 절대 경로를 지정해준다.

```
$ rdd = sc.textFile('file:///kikang/spark3/README.md')
```

즉, 로컬에서 파일을 읽어오겠다는 뜻이다. 근데 만약에 이와 같이 경로를 지정하면 READMD.md라는 파일이 각 워커의 로컬 경로에 모두 존재해야 한다. 만약 파일 크기가 매우 큰 빅데이터라면 디스크 낭비가 발생할 수 밖에 없다. 따라서 hdfs에 파일을 올리는 것을 추천한다.

rdd.count() 라는 job을 스파크가 어떻게 수행했는지 UI로 확인해보자.



URL: spark://hadoop-master-01:7177

Alive Workers: 3 Cores in use: 6 Total, 6 Used

Memory in use: 21.0 GiB Total, 3.0 GiB Used

Resources in use:

Applications: 1 Running, 3 Completed Drivers: 0 Running, 0 Completed

Status: ALIVE

→ Workers (3)

Worker Id	Address	State	Cores	Memory	Resources
worker-20201130105715-10.128.0.7-36512	10.128.0.7:36512	ALIVE	2 (2 Used)	7.0 GiB (1024.0 MiB Used)	
worker-20201130105715-10.128.0.8-35666	10.128.0.8:35666	ALIVE	2 (2 Used)	7.0 GiB (1024.0 MiB Used)	
worker-20201130105715-10.128.0.9-39881	10.128.0.9:39881	ALIVE	2 (2 Used)	7.0 GiB (1024.0 MiB Used)	

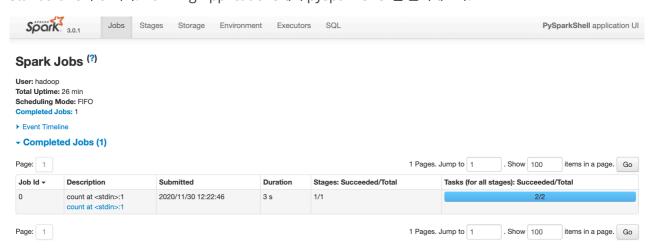
→ Running Applications (1)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration	
app-20201130122112-0003 (kill)	<u>PySparkShell</u>	6	1024.0 MiB		2020/11/30 12:21:12	hadoop	RUNNING	9.2 min	

→ Completed Applications (3)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
app-20201130114342-0001	Spark shell	6	1024.0 MiB		2020/11/30 11:43:42	hadoop	FINISHED	37 min
app-20201130115212-0002	PySparkShell	0	1024.0 MiB		2020/11/30 11:52:12	hadoop	FINISHED	4.3 min
app-20201130111835-0000	Spark shell	6	1024.0 MiB		2020/11/30 11:18:35	hadoop	FINISHED	13 min

standalone의 UI이다. Running Applications에서 pyspark shell을 클릭해보자.

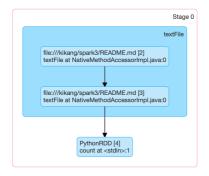


방금 수행된 rdd.count() job을 확인할 수 있다. 좀 더 자세히 확인해보자.

Details for Stage 0 (Attempt 0)

Total Time Across All Tasks: 4 s Locality Level Summary: Process local: 2 Input Size / Records: 6.6 KiB / 108 Associated Job Ids: 0

▼ DAG Visualization



- ▶ Show Additional Metrics
- ▶ Event Timeline

Summary Metrics for 2 Completed Tasks

Metric	Min	25th percentile	Median	75th percentile	Max
Duration	2 s	2 s	2 s	2 s	2 s
GC Time	92.0 ms	92.0 ms	0.1 s	0.1 s	0.1 s
Input Size / Records	2.2 KiB / 49	2.2 KiB / 49	4.4 KiB / 59	4.4 KiB / 59	4.4 KiB / 59

Showing 1 to 3 of 3 entries

Aggregated Metrics by Executor

Tasks (2)



DAG Visualization에는 이 코드가 어떠한 physical plan을 거쳐서 수행됐는지 보여준다. 처음에 README.md을 읽고, 그 후에 count action을 취한, 아주 간단한 스파크 잡이다.

Tasks을 보자. Executor ID가 0,1인 워커에서 이 잡이 분산되어 실행되었음을 확인할 수 있다.

파이썬이나 R에서 어떤 파일을 읽어오면 변수에 저장하기 마련이다. 그런데 스파크는 애초에 빅데이터를 처리하기 위해 만들어진 프레임워크이다. 따라서 엄청 큰 파일을 읽어오면, 이 읽어온 것을 어디에 저장하는 것을 생각하지 않는다. 따라서 위와 같이 한 번 README.md에 대해서 count job을 수행하고 또 이 job이 필요하다면, 다시 처음부터 불러와서 count을 해야하는 것이다.